





# TECNOLÓGICO NACIONAL DE MÉXICO INSTITUTO TECNOLÓGICO DE TIJUANA

# SUBDIRECCIÓN ACADÉMICA DEPARTAMENTO DE SISTEMAS Y COMPUTACIÓN

#### **SEMESTRE:**

Enero - Junio 2020

#### **CARRERA:**

Ing. Tecnologías de la Información y Comunicaciones

#### **MATERIA:**

**Datos Masivos** 

#### **UNIDAD A EVALUAR:**

Unidad 1

## NOMBRE Y NÚMERO DE CONTROL DEL ALUMNO:

Diaz Martinez Ruben Emilio # 15210791

## NOMBRE DEL MAESTRO (A):

Dr. Jose Christian Romero Hernandez

```
import org.apache.spark.sql.SparkSession
val spark = SparkSession.builder().getOrCreate()
val df = spark.read.option("header",
"true").option("inferSchema","true")csv("CitiGroup2006 2008")
df.select(sumDistinct("Sales")).show()
df.select(last("Company")).show() //last data in company
df.select(first("Person")).show() first data in person
//4.var_pop
df.select(var_pop("Sales")).show()
df.select(avg("Sales")).show()
df.select(collect_list("Sales")).show()
df.select(var samp("Sales")).show()
```

```
df.select(sum("Sales")).show()
df.select(stddev pop("Sales")).show()
df.select(skewness("Sales")).show()
//11.min
df.select(min("Sales")).show()
df.select(kurtosis("Sales")).show()
df.select(collect_set("Sales")).show()
df.select(approx_count_distinct("Company")).show()
df.select(mean("Sales")).show()
```

```
df.first

//17 Returns the dataframe columns

df.columns

//18 Add a column that derives from the high and Volume column

val df2 = df.withColumn("HV Ratio", df("High")+df("Volume"))

//19 Choose the volume column min

df.select(min("Volume")).show()

//20 Choose the volume column max

df.select(max("Volume")).show()
```